Министерство науки и высшего образования Российской Федерации
ФГАОУ ВО «УрФУ имени первого Президента России Б.Н. Ельцина»
Кафедра «Вычислительной математики и компьютерных наук»

Оценка работы_____
Шека Андрей Сергеевич

Применение искусственных нейронных сетей для анализа фазовых переходов и механических свойств никелевых суперсплавов

ОТЧЕТ
Учебная практика

Руководитель практики от предприятия (организации) - Шека А. С.
ФИО руководителя **Подпись**

Студент Эсаулов Н.В.
ФИО студента

Специальность (направление подготовки) 02.04.01 Математика и компьютерные науки

Группа МЕНМ-150201

Екатеринбург 2026

РЕФЕРАТ

Настоящая работа посвящена воспроизведению и анализу методов нейросетевого моделирования свойств никелевых жаропрочных сплавов. Рассмотрены две задачи: прогнозирование температуры сольвуса γ'-фазы по химическому составу сплава и моделирование зависимости прочности никелевых суперсплавов от параметра Ларсона–Миллера.

В первой части работы исследуется подход к прогнозированию температуры сольвуса с использованием искусственной нейронной сети с дифференциальным слоем. Особое внимание уделено подготовке входных данных: учету априорной информации о физической роли элементов в структуре жаропрочных сплавов. Такой подход позволяет представить состав сплава в более физически обоснованной форме и повысить интерпретируемость модели.

Во второй части рассматривается модель прогнозирования жаропрочности никелевых суперсплавов на основе байесовской регуляризованной искусственной нейронной сети BRANN. В качестве входных признаков используются химический состав и нормированный параметр Ларсона–Миллера, объединяющий температуру и время испытания. Для повышения устойчивости обучения прочность предварительно преобразуется в логарифмическую форму.

В работе описаны теоретические основы, подготовка данных, структура применяемых нейронных сетей, особенности реализации вычислительных экспериментов и основные результаты моделирования. Показано, что использование методов машинного обучения позволяет учитывать сложные нелинейные зависимости между химическим составом, температурно-временными условиями и свойствами никелевых жаропрочных сплавов.

Ключевые слова: никелевые жаропрочные сплавы, суперсплавы, температура сольвуса, γ'-фаза, искусственная нейронная сеть, дифференциальный слой, BRANN, байесовская регуляризация, параметр Ларсона–Миллера, жаропрочность.

СОДЕРЖАНИЕ

РЕФЕРАТ 2
Словарь терминов 5
ВВЕДЕНИЕ 8
1 Моделирование температуры сольвуса никелевых жаропрочных сплавов с использованием нейронной сети 10
1.1 Теоретические основы 10
1.1.1 Никелевые жаропрочные сплавы и температура сольвуса . 10
1.1.2 Влияние легирующих элементов 10
1.2 Описание модели 11
1.2.1 Нейронная сеть 11
1.2.2 Учет априорной физической информации 11
1.2.3 Дифференцирующий слой 12
1.3 Реализация модели 13
1.3.1 Общая схема вычислительного эксперимента 13
1.3.2 Метрики качества 13
1.4 Результаты моделирования 14
1.4.1 Точечные результаты на тестовой выборке 14
1.4.2 Оценка качества модели по кросс-валидации 15
1.4.3 Неопределённость метрик по методу бутстрэпа 15
1.5 Выводы по главе 16
2 Прогнозирование жаропрочности никелевых суперсплавов с использованием BRANN и параметра Ларсона–Миллера 17
2.1 Теоретические основы 17
2.1.1 Жаропрочность никелевых суперсплавов 17
2.1.2 Параметр Ларсона–Миллера 17
2.2 Исходные данные 18
2.2.1 Структура базы данных 18
2.2.2 Преобразование химического состава и нормализация относительно никеля 19
2.2.3 Целевая переменная 20
2.3 Описание модели BRANN 20
2.3.1 Байесовская нейронная сеть 20
2.3.2 Архитектура нейронной сети 21
2.4 Реализация вычислительного эксперимента 22

2.4.1 Процедура обучения 22
2.4.2 Критерии оценки качества 24
2.5 Результаты моделирования 25
2.5.1 Результаты групповой кросс-валидации 25
2.5.2 Оценка точности на отложенной тестовой выборке 26
2.5.3 Сопоставление прогнозов с экспериментальными данными 26
2.6 Выводы по главе 28
ЗАКЛЮЧЕНИЕ 29
БИБЛИОГРАФИЧЕСКИЙ СПИСОК 30

Словарь терминов

Никелевые жаропрочные сплавы - сложнолегированные металлические материалы на основе никеля, предназначенные для работы при высоких температурах, длительных нагрузках и в агрессивных средах. Характеризуются высокой жаропрочностью, коррозионной стойкостью и структурной стабильностью.

Суперсплавы - класс высоколегированных сплавов, сохраняющих механические свойства при температурах, близких к температуре плавления. В данной работе под суперсплавами преимущественно понимаются никелевые жаропрочные сплавы.

γ-матрица - основная фаза никелевых жаропрочных сплавов, представляющая собой твердый раствор на основе никеля с гранецентрированной кубической решеткой. В γ-матрице распределены упрочняющие фазы.

γ'-фаза - упрочняющая интерметаллидная фаза, она является одним из основных факторов высокой жаропрочности никелевых суперсплавов.

γ''-фаза - упрочняющая метастабильная интерметаллидная фаза, характерная для некоторых никелевых сплавов, содержащих ниобий. Вносит вклад в повышение прочности, особенно при промежуточных температурах.

Температура сольвуса - температура, выше которой определенная фаза полностью растворяется в матрице сплава. В данной работе особое значение имеет температура сольвуса γ'-фазы, обозначаемая как T_{solvus}.

T_{solvus} - обозначение температуры сольвуса. Используется как целевая переменная при моделировании фазовой стабильности никелевых суперсплавов.

Легирование - введение в сплав дополнительных химических элементов с целью изменения его структуры и свойств. В никелевых суперсплавах легирование используется для повышения прочности, жаростойкости, коррозионной стойкости и фазовой стабильности.

Параметр Ларсона–Миллера - температурно-временной параметр, объединяющий температуру и время выдержки или разрушения:

$$P_{LM} = T(C + \log_{10} \tau).$$

Используется для описания длительной прочности и деградации материала при высоких температурах.

P^*_{LM} нормированная форма параметра Ларсона–Миллера:

$$P^*_{LM} = T(20 + \log_{10}\tau) \cdot 10^{-5}.$$

Нормировка используется для согласования масштаба данного параметра с концентрациями элементов во входном векторе нейронной сети.

Предел прочности - максимальное механическое напряжение, которое материал выдерживает до разрушения. Обозначается как σ.

σ - обозначение прочности или предела прочности сплава. В одной из моделей является целевой переменной, предсказываемой нейронной сетью.

Многослойный персептрон - тип нейронной сети прямого распространения, состоящий из входного слоя, одного или нескольких скрытых слоев и выходного слоя.

Скрытый слой - внутренний слой нейронной сети, в котором выполняется нелинейное преобразование входных данных.

Выходной слой - последний слой нейронной сети, формирующий итоговое предсказание модели.

Функция активации - нелинейная функция, применяемая к выходу нейрона. Позволяет нейронной сети моделировать нелинейные зависимости.

Обучение нейронной сети - процесс подбора весов и смещений сети с целью минимизации ошибки между предсказанными и экспериментальными значениями.

Обратное распространение ошибки - алгоритм вычисления градиентов ошибки по параметрам нейронной сети, используемый при ее обучении.

Переобучение - ситуация, при которой модель слишком хорошо запоминает обучающую выборку, но плохо предсказывает новые данные.

Регуляризация - метод ограничения сложности модели для уменьшения переобучения и повышения обобщающей способности.

BRANN - Bayesian Regularized Artificial Neural Network — искусственная нейронная сеть с байесовской регуляризацией. Используется для повышения устойчивости модели к переобучению.

Бутстреп - метод многократного случайного формирования обучающих и проверочных выборок из исходных данных. Используется для повышения надежности оценки модели.

Обучающая выборка - часть данных, используемая для настройки параметров модели.

Валидационная выборка - часть данных, используемая для контроля качества модели во время обучения и предотвращения переобучения.

Тестовая выборка - независимая часть данных, используемая для окончательной оценки качества обученной модели.

Априорная информация - заранее известные сведения о физической природе объекта моделирования. В данной работе это информация о роли легирующих элементов в структуре и свойствах суперсплавов.

Матрица связей - матрица, описывающая принадлежность легирующих элементов к различным группам влияния. Используется для внедрения физической информации в архитектуру нейронной сети.

Дифференциальный слой - слой нейронной сети, передающий информацию о чувствительности выходного параметра к изменению входных признаков.

MSE - Mean Squared Error — среднеквадратичная ошибка:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 .$$

RMSE - Root Mean Squared Error — корень из среднеквадратичной ошибки. В отчете также используется относительная форма RMSE для оценки ошибки прогноза прочности.

RMAE - Relative Mean Absolute Error — относительная средняя абсолютная ошибка. Используется для оценки точности прогноза температуры сольвуса.

RRMSE - Relative Root Mean Squared Error — относительная среднеквадратичная ошибка. Используется для оценки качества модели при прогнозировании температуры сольвуса.

Химический состав - совокупность концентраций элементов, входящих в сплав. В моделях машинного обучения химический состав используется как входной вектор признаков.

Вектор признаков - набор численных характеристик объекта, передаваемый на вход модели. Для суперсплавов включает концентрации легирующих элементов и, при необходимости, параметр Ларсона–Миллера.

Целевая переменная - величина, которую необходимо предсказать с помощью модели. В данном отчете целевыми переменными являются температура сольвуса T_{solvus} и прочность σ.

ВВЕДЕНИЕ

Актуальность. В современной промышленности и материаловедении никелевые суперсплавы играют критически важную роль, особенно в авиастроении и энергетике, где требуются материалы, способные выдерживать экстремальные температуры и механические нагрузки. Традиционные методы подбора состава и прогнозирования свойств таких сплавов требуют проведения дорогостоящих и длительных физических экспериментов. В связи с этим, применение методов машинного обучения и искусственных нейронных сетей для ускорения процесса разработки новых материалов является высокоактуальной задачей.

Проблема. Несмотря на наличие больших массивов экспериментальных данных, классические эмпирические модели и физические уравнения часто не способны точно описать сложные нелинейные зависимости между химическим составом суперсплавов, параметрами термической обработки и их итоговыми физико-механическими свойствами. Это приводит к высокой погрешности прогнозов и необходимости многократного перебора вариантов при создании новых марок сплавов.

Целью работы является численное воспроизведение и анализ современных подходов к прогнозированию термических и механических свойств никелевых суперсплавов с использованием архитектур глубокого обучения и байесовских нейронных сетей.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Изучить и воспроизвести модель глубокого обучения с дифференциальным слоем для прогнозирования температуры сольвуса никелевых суперсплавов.
2. Реализовать байесовскую регуляризованную нейронную сеть (BRANN) для прогнозирования предела прочности суперсплавов в зависимости от параметра Ларсона-Миллера.
3. Провести сравнительный анализ точности полученных нейросетевых моделей с оригинальными данными из научных статей.

Краткое содержание и результаты. В ходе выполнения работы был предобработан датасет, описывающий химический состав и свойства никелевых суперсплавов. Были реализованы две нейросетевые архитектуры. В

результате воспроизведения первой модели удалось достичь высокой точности предсказания температуры сольвуса. Во второй части работы реализован ансамбль байесовских нейронных сетей для прогнозирования длительной прочности по химическому составу, температуре испытания и параметру Ларсона–Миллера. Качество модели оценено с помощью групповой кросс-валидации и проверки на отложенных составах. Полученные результаты показывают перспективность применения методов машинного обучения для прогнозирования свойств никелевых суперсплавов.

1 Моделирование температуры сольвуса никелевых жаропрочных сплавов с использованием нейронной сети

1.1 Теоретические основы

1.1.1 Никелевые жаропрочные сплавы и температура сольвуса

Никелевые жаропрочные сплавы представляют собой сложнолегированные металлические материалы, предназначенные для работы при высоких температурах, механических нагрузках и агрессивных средах. Их высокая жаропрочность обусловлена многофазной структурой и наличием упрочняющих выделений, главным образом фаз γ' и γ''. Основой большинства никелевых суперсплавов является γ-матрица на основе никеля. В ней распределены частицы упрочняющей γ'-фазы. Также в зависимости от состава могут присутствовать карбиды, бориды и другие интерметаллидные соединения.

Одним из важнейших параметров, характеризующих фазовую стабильность никелевого жаропрочного сплава, является температура сольвуса γ'-фазы T_{solvus}. Температура сольвуса соответствует температуре, выше которой упрочняющая фаза начинает растворяться в матрице. При превышении этой температуры структура сплава теряет устойчивость, что приводит к снижению прочностных характеристик.

Следовательно, прогнозирование температуры сольвуса по химическому составу является важной задачей при разработке новых жаропрочных сплавов и оптимизации уже существующих композиций.

1.1.2 Влияние легирующих элементов

Химический состав никелевых жаропрочных сплавов может включать большое количество элементов: Th, C, Cr, Co, Mo, W, Al, Ti, Nb, B, Fe, Y, Zr, Ta, Re, Ru, V, La, S, Si, Mn, P, Hf, Cu, Ge, Ga, Ni. Каждый из них выполняет определенную функцию.

Например, элементы Al, Ti, Ta и Nb участвуют в образовании упрочняющих интерметаллидных фаз. Cr и Al повышают стойкость к окислению и коррозии. Co, Mo, W, Re и Ta могут упрочнять твердый раствор. C, B, Zr и Hf влияют на границы зерен и образование карбидных фаз.

Влияние легирующих элементов является существенно нелинейным. Кроме того, один и тот же элемент может одновременно участвовать в нескольких физических механизмах. Поэтому построение простой аналитической зависимости между химическим составом и температурой сольвуса является затруднительным.

1.2 Описание модели

1.2.1 Нейронная сеть

Для прогнозирования температуры сольвуса используется искусственная нейронная сеть прямого распространения. В общем виде модель можно записать следующим образом:

$$\hat{T}_{\text{solvus}} = f_{\theta}\left(x_1, x_2, \ldots, x_m\right), \tag{1.1}$$

где $\hat{T}_{\text{solvus}}$ — предсказанное значение температуры сольвуса, x_i — процентное сожержание легирующего элемента, θ — обучаемые параметры модели.

Нейронная сеть выполняет роль нелинейного аппроксиматора, который устанавливает зависимость между химическим составом и температурой сольвуса. Преимущество такого подхода заключается в способности учитывать сложные нелинейные взаимодействия между элементами, которые трудно описать классическими аналитическими выражениями.

1.2.2 Учет априорной физической информации

Особенностью рассматриваемой модели является включение в архитектуру сети априорной информации о роли легирующих элементов. Элементы группируются по их влиянию на свойства сплава: твердорастворное упрочнение, образование карбидов, формирование γ'-фазы, повышение стойкости к окислению, стабилизация границ зерен и т.д.

Эта информация может быть представлена в виде матрицы связей:

$$R = [r_{gi}], \tag{1.2}$$

где r_{gi} показывает, относится ли элемент i к группе влияния g. Если элемент входит в соответствующую группу, то $r_{gi} = 1$, иначе $r_{gi} = 0$.

Для каждой группы можно сформировать обобщенный сигнал:

$$s_g = \sum_{i=1}^{m} r_{gi} x_i, \tag{1.3}$$

где s_g — суммарный вклад элементов, относящихся к g-й группе.

Таким образом, нейронная сеть получает не только численные концентрации элементов, но и информацию об их физической роли в структуре сплава.

1.2.3 Дифференцирующий слой

Дифференцирующий слой формирует два нелинейных преобразования входного сигнала группы:

$$\mathbf{p}_g = \tanh\left(W_g^+ \mathbf{x}_g + \mathbf{b}_g^+\right),$$

$$\mathbf{n}_g = \tanh\left(W_g^- \mathbf{x}_g + \mathbf{b}_g^-\right),$$

где W_g^+ и W_g^- — обучаемые матрицы весов, а $\mathbf{b}_g^+$ и $\mathbf{b}_g^-$ — векторы смещений. В данной модели смещениям установлены значения

$$\mathbf{b}_g^+ = 0.5, \qquad \mathbf{b}_g^- = -0.5.$$

Дифференцированный сигнал определяется как разность двух нелинейных преобразований:

$$\mathbf{d}_g = \mathbf{p}_g - \mathbf{n}_g.$$

Такое представление позволяет сети учитывать не только суммарное содержание элементов в группе, но и различия в характере их влияния на целевое свойство.

Выход g-й ветви дифференцирующего слоя записывается в виде

$$\mathbf{h}_g = [s_g, \mathbf{p}_g, \mathbf{n}_g, \mathbf{d}_g].$$

После обработки всех групп выходные векторы объединяются:

$$\mathbf{h} = [\mathbf{h}_1, \mathbf{h}_2, \ldots, \mathbf{h}_G],$$

где G — число групп легирующих элементов.

Итоговый вход последующей полносвязной части сети формируется путем объединения исходного вектора состава и группового дифференцированного сигнала:

$$\mathbf{z} = [\mathbf{x}, \mathbf{h}] .$$

Затем вектор $\mathbf{z}$ поступает на полносвязную нейронную сеть:

$$\hat{y} = f_\theta(\mathbf{z}),$$

где $\hat{y}$ — прогнозируемое значение температуры сольвуса, а f_θ — обучаемая нелинейная функция, реализуемая скрытыми слоями нейронной сети.

Таким образом, дифференцирующий слой выполняет две функции. Во-первых, он внедряет в архитектуру сети априорную информацию о физической роли легирующих элементов. Во-вторых, он формирует дополнительные нелинейные признаки, описывающие групповой и дифференцированный вклад элементов в прогнозируемое свойство.

1.3 Реализация модели

1.3.1 Общая схема вычислительного эксперимента

Реализация модели включает следующие этапы:

1. формирование матрицы связей, описывающей физическую роль легирующих элементов;
2. построение глубокой нейронной сети с дифференциальным слоем;
3. обучение модели на подготовленных данных;
4. оценка точности прогноза по выбранным метрикам.

1.3.2 Метрики качества

Для оценки качества прогноза могут использоваться относительная средняя абсолютная ошибка и относительная среднеквадратичная ошибка.

Относительная средняя абсолютная ошибка определяется выражением:

$$RMAE = \frac{1}{n} \sum_{i=1}^{n} \left| \frac{T_i - \hat{T}_i}{T_i} \right| \cdot 100\%, \tag{1.4}$$

где T_i — экспериментальное значение температуры сольвуса, $\hat{T}_i$ — предсказанное значение, n — количество объектов в выборке.

Относительная среднеквадратичная ошибка определяется как:

$$RRMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(\frac{T_i - \hat{T}_i}{T_i}\right)^2}. \tag{1.5}$$

1.4 Результаты моделирования

В результате применения нейронной сети была получена модель, способная прогнозировать температуру сольвуса никелевых жаропрочных сплавов по их химическому составу. Использование априорной информации о роли элементов позволило повысить физическую обоснованность входных данных.

По данным воспроизводимой статьи, модель показала достаточно высокую точность: относительная средняя абсолютная ошибка составила около $RMAE = 5.89\%$, а относительная среднеквадратичная ошибка — около $RRMSE = 0.09$.

1.4.1 Точечные результаты на тестовой выборке

На тестовой выборке были получены предсказания $\hat{y}$ и вычислены ошибки. Для иллюстрации качества работы модели в таблице приведены 5 случаев с наибольшими значениями ошибки на тесте.

y_{true}	y_{pred}	$\lvert e \rvert$	$rel_error(\%)$
773.15	1191.20	418.05	54.07
973.15	1285.83	312.68	32.13
1023.15	1224.65	201.50	19.69
1373.15	1154.06	219.08	15.95
1143.15	967.36	175.78	15.37

Таблица 1 — Пять худших предсказаний на тестовой выборке

1.4.2 Оценка качества модели по кросс-валидации

Для проверки устойчивости обучения использовалась кросс-валидация: модель переобучалась на каждом фолде и вычислялись метрики. Итоговые значения представлены медианой и дисперсией по фолдам.

Метрика	Медиана	Дисперсия
RRMAE (%)	4.36	0.79
RRMSE	0.08	0.0001

Таблица 2 — Сводные результаты кросс-валидации

1.4.3 Неопределённость метрик по методу бутстрэпа

Для дополнительно оценки устойчивости метрик вычислялись распределения RRMAE и RRMSE с помощью бутстрэпа. Квантили 2.5% и 97.5% соответствуют приближённому доверительному интервалу, а вертикальная линия (медиана) показывает центральную тенденцию. Рисунки 1–2 иллюстрируют полученные распределения.

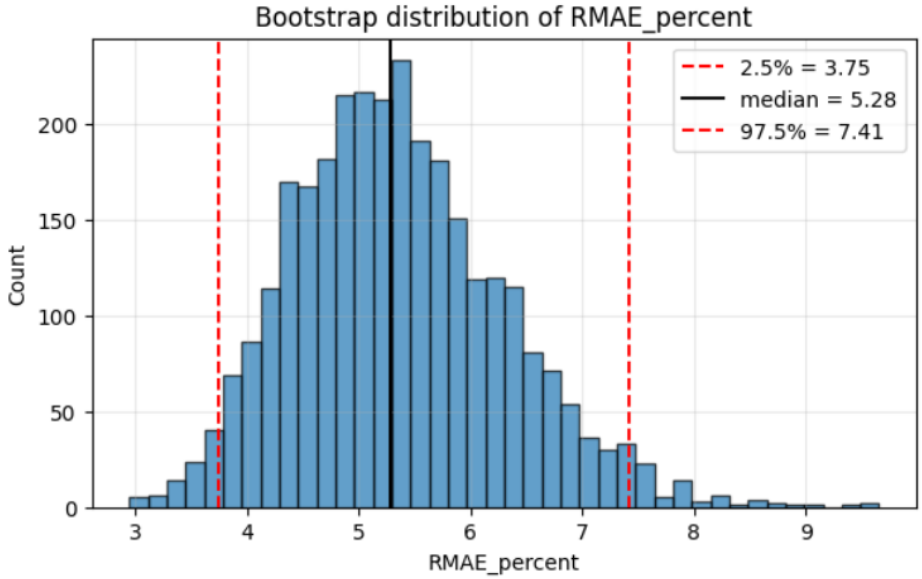


Рисунок 1 — Распределение RRMAE (%) по бутстрэп-выборкам

Итак, таблица 1 показывает поведение модели на тесте в наиболее проблемных случаях, кросс-валидация (табл. 2) оценивает устойчивость качества при повторном обучении на различных фолдах, а бутстрэп (рис. 1–2) предоставляет распределения метрик и их доверительные интервалы.

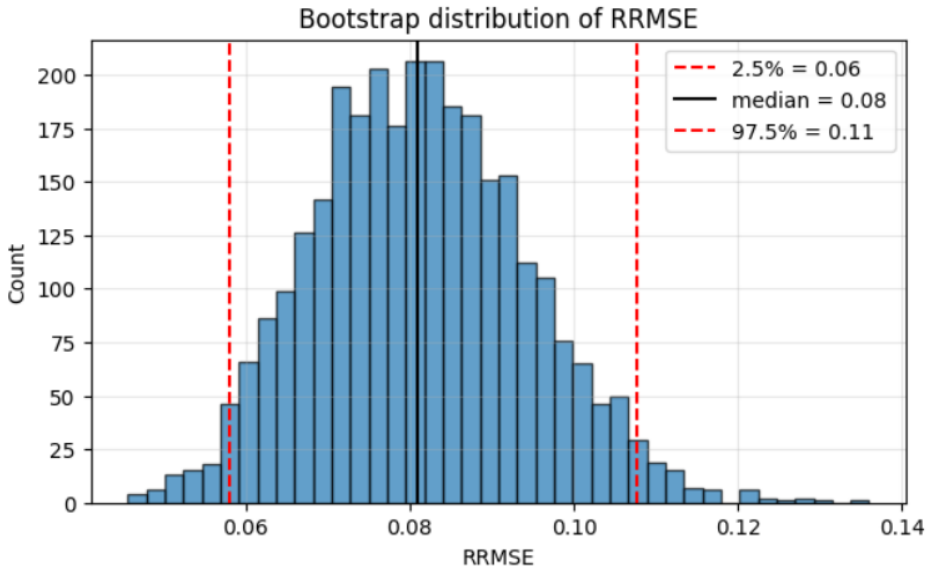


Рисунок 2 — Распределение RRMSE по бутстрэп-выборкам

1.5 Выводы по главе

Полученные результаты показывают, что нейронная сеть с дифференциальным слоем может быть использована для прогнозирования температуры сольвуса сложнолегированных никелевых суперсплавов. Такой подход особенно эффективен в условиях, когда аналитическое описание зависимости между составом и свойствами затруднено из-за высокой нелинейности и многокомпонентности системы.

Основными особенностями модели являются:

– учет физической роли легирующих элементов;

– применение дифференциального слоя для анализа чувствительности модели.

Эта глава, была попыткой воспроизвести статью [1]

2 Прогнозирование жаропрочности никелевых суперсплавов с использованием BRANN и параметра Ларсона–Миллера

2.1 Теоретические основы

2.1.1 Жаропрочность никелевых суперсплавов

Жаропрочность является одной из ключевых характеристик никелевых суперсплавов. Она определяет способность материала сохранять прочность при длительном воздействии высокой температуры и механической нагрузки.

В условиях высокотемпературной эксплуатации структура суперсплава постепенно деградирует. Происходит укрупнение упрочняющих фаз, изменение морфологии выделений, перераспределение легирующих элементов и накопление повреждений. В результате предел прочности σ снижается.

Для описания изменения прочности при различных температурах и временах выдержки удобно использовать обобщенные температурно-временные параметры. Одним из наиболее распространенных является параметр Ларсона–Миллера.

2.1.2 Параметр Ларсона–Миллера

Параметр Ларсона–Миллера объединяет температуру и время выдержки в одну величину:

$$P_{LM} = T\left(20 + \log_{10}\tau\right), \tag{2.1}$$

где T — температура испытания, τ — время выдержки или длительность испытания.

В рассматриваемой работе используется нормированная форма параметра:

$$P^{*}_{LM} = T\left(20 + \log_{10}\tau\right) \cdot 10^{-5}. \tag{2.2}$$

Для удобства численного представления параметр Ларсона–Миллера умножался на 10^{-5}, как в исходной работе. Перед обучением все входные

признаки, включая температуру и масштабированный параметр Ларсона–Миллера, дополнительно стандартизировались. Параметры стандартизации вычислялись только по обучающей части соответствующего разбиения.

Параметр P^*_{LM} отражает степень температурно-временного воздействия на материал. При увеличении этого параметра прочность сплава, как правило, снижается вследствие термической деградации структуры.

2.2 Исходные данные

2.2.1 Структура базы данных

Для обучения модели использовалась база данных никелевых суперсплавов, содержащая сведения о химическом составе и результатах механических испытаний. После проверки и очистки набор данных содержал 1042 записи, объединённые в 481 группу химического состава. Каждая запись характеризовала состав сплава, температуру испытания T, продолжительность τ и измеренную предельную прочность σ. Значения σ находились в диапазоне от 29 до 1550 МПа.

В исходной таблице встречались записи, для которых одинаковым значениям всех доступных входных признаков соответствовали разные значения прочности. Поскольку сведения о технологии получения, термообработке и ориентации образца в наборе отсутствовали, такие записи были объединены по медиане. Тем самым целевая переменная модели интерпретируется как типичное, а не максимально достижимое значение прочности при заданных доступных признаках.

В качестве входных признаков использовались содержания легирующих элементов:

$$\mathbf{x} = (c_1, c_2, \ldots, c_m, T.K, P^*_{LM}), \tag{2.3}$$

где c_i — концентрация i-го легирующего элемента, m — количество учитываемых элементов, $T.K$ — температура, P^*_{LM} — параметр Ларсона–Миллера.

В базе данных учитывались следующие элементы:

$$\begin{gathered}\mathrm{Th, C, Cr, Co, Mo, W, Al, Ti, Nb, B, Fe, Y, Zr, Ta,}\\ \mathrm{Re, Ru, V, La, S, Si, Mn, P, Hf, Cu, Ge, Ga, Ni}\end{gathered} \tag{2.4}$$

Отсутствующее содержание отдельного элемента принималось равным нулю. Химические составы округлялись до пяти знаков после запятой только при формировании идентификатора группы. Это позволяло считать одинаковыми составы, различавшиеся лишь из-за формы числовой записи.

2.2.2 Преобразование химического состава и нормализация относительно никеля

Исходные данные о химическом составе никелевых суперсплавов в большинстве случаев задаются в массовых процентах. Однако для описания фазообразования и взаимодействия легирующих элементов более физически обоснованным является использование атомных соотношений, поскольку образование фаз определяется числом атомов, а не их массой.

Поэтому на первом этапе выполнялось преобразование массовых концентраций в атомные доли. Для каждого элемента вычислялась величина

$$q_i = \frac{w_i}{A_i}, \tag{2.5}$$

где w_i — массовое содержание i-го элемента, а A_i — его атомная масса. Затем атомная доля элемента определялась как

$$x_i = \frac{q_i}{\sum\limits_{j=1}^{m} q_j} = \frac{w_i/A_i}{\sum\limits_{j=1}^{m} w_j/A_j}, \tag{2.6}$$

где m — количество элементов, входящих в химический состав сплава.

Так как никель является основой рассматриваемых суперсплавов, на следующем этапе атомные доли легирующих элементов нормировались относительно атомной доли никеля:

$$z_i = \frac{x_i}{x_{\mathrm{Ni}}}, \tag{2.7}$$

где z_i — относительное содержание i-го легирующего элемента по отношению к никелевой матрице, x_i — атомная доля данного элемента, а x_{Ni} — атомная доля никеля.

Таким образом, величина z_i показывает, сколько атомов легирующего элемента приходится на один атом никеля. Например, если $z_{\mathrm{Cr}} = 0.12$, это означает, что на один атом никеля приходится приблизительно 0.12 атома хрома, или около 12 атомов хрома на 100 атомов никеля.

Итоговый входной вектор модели записывался в виде

$$\mathbf{x} = (z_1, z_2, \ldots, z_m, T.K, P^*_{LM}), \tag{2.8}$$

где z_i — атомная доля легирующего элемента, нормированная относительно никеля.

Такое преобразование имеет несколько преимуществ. Во-первых, оно переводит химический состав из массовой формы в атомную, что лучше соответствует физической природе фазовых превращений. Во-вторых, никель исключается из набора независимых признаков, поскольку он является матричным элементом. В-третьих, нормировка относительно никеля приводит значения входных переменных к близкому численному диапазону, что облегчает обучение нейронной сети методом обратного распространения ошибки.

2.2.3 Целевая переменная

Целевой переменной являлась длительная прочность σ в МПа при заданных температуре и продолжительности испытания. Логарифмическое преобразование прочности не применялось.

Перед обучением значения целевой переменной стандартизировались:

$$\hat{y} = \frac{\sigma - \mu_\sigma}{s_\sigma}, \tag{2.9}$$

где μ_σ и s_σ — среднее значение и стандартное отклонение прочности, вычисленные только по обучающей части соответствующего фолда.

Нейронная сеть прогнозировала стандартизированную величину $\hat{y} = f(\mathbf{x})$. Для получения результата в МПа выполнялось обратное преобразование:

$$\sigma = \mu_\sigma + s_\sigma \hat{y}. \tag{2.10}$$

При финальном обучении параметры стандартизации вычислялись по всей выборке для обучения и настройки модели. Тестовые данные при их вычислении не использовались.

2.3 Описание модели BRANN

2.3.1 Байесовская нейронная сеть

Для прогнозирования предельной прочности использовалась байесовская нейронная сеть на основе многослойного персептрона. Реализация

основана на подходе, рассмотренном в статье [2], но отличается архитектурой и способом байесовского обучения.

В классической постановке байесовской регуляризации применяется функционал:

$$F = \beta E_D + \alpha E_W, \tag{2.11}$$

где E_D — квадратичная ошибка прогноза, E_W — сумма квадратов весов, а α и β определяют соотношение между этими составляющими. Такой функционал связан с предположением о нормальном распределении ошибок наблюдений и нормальном априорном распределении весов.

В данной реализации параметры сети рассматриваются как случайные величины. При обучении оцениваются их распределения с учётом наблюдаемых данных. Это позволяет получать как точечный прогноз, так и оценку его неопределённости.

В данной реализации использовались распределения Стьюдента: для весов и смещений задавалось априорное распределение с общим случайным масштабом, а для наблюдений — распределение с центром, равным выходу сети:

$$y_i \mid \hat{y}_i, s_{\text{noise}} \sim \text{StudentT}\left(\nu = 4,\, \hat{y}_i,\, s_{\text{noise}}\right). \tag{2.12}$$

Здесь y_i — наблюдаемая стандартизированная прочность; $\hat{y}_i$ — прогноз сети в той же шкале; $\nu = 4$ — заданное число степеней свободы; $s_{\text{noise}} > 0$ — оцениваемый при обучении параметр масштаба разброса.

По сравнению с нормальным распределением распределение Стьюдента слабее штрафует большие отклонения, что позволяет уменьшить влияние отдельных аномальных наблюдений.

В качестве функции потерь применялась отрицательная ELBO, реализованная в Pyro классом `Trace_ELBO`. Вычисление функции потерь и её градиентов выполнялось библиотекой на основе заданной вероятностной модели и выбранного приближения распределения параметров.

2.3.2 Архитектура нейронной сети

Нейронная сеть представляла собой многослойный персептрон с 28 входными признаками и тремя скрытыми слоями, содержащими 48, 24 и 12

нейронов. В скрытых слоях использовалась функция активации SiLU. Выходной слой состоял из одного нейрона без функции активации и выдавал прогноз стандартизированной прочности.

Входные данные последовательно проходили через все слои сети:

$$\mathbf{x} \longrightarrow \mathrm{Hidden}(48) \longrightarrow \mathrm{Hidden}(24) \longrightarrow \mathrm{Hidden}(12) \longrightarrow \hat{y}, \tag{2.13}$$

где $\mathbf{x}$ — вектор стандартизированных входных признаков, а $\hat{y}$ — прогноз стандартизированной прочности. Для получения результата в МПа выполнялось обратное преобразование стандартизации.

Перед байесовским обучением выполнялось 1200 шагов предварительного обучения с функцией потерь Smooth L1. Этот этап использовался для начальной настройки весов сети. Полученные значения служили для инициализации последующего байесовского обучения.

2.4 Реализация вычислительного эксперимента

2.4.1 Процедура обучения

После очистки набор данных содержал 1042 записи, соответствующие 481 уникальному химическому составу. Разделение выполнялось по группам состава: все записи одного состава при различных условиях испытания попадали только в одну часть выборки.

Для формирования тестовой части создавались 200 случайных групповых разбиений с выделением около 10 % составов. Выбиралось разбиение, в котором доля тестовых строк была наиболее близка к 10 %. Значения прочности и показатели качества модели при выборе разбиения не использовались.

В результате выборка для обучения и настройки модели содержала 938 записей о 432 составах, а отложенная тестовая выборка — 104 записи о 49 составах. Пересечение составов между частями отсутствовало. Дополнительное размножение наблюдений и балансировка по диапазонам прочности не применялись.

Входной вектор включал 26 атомных отношений легирующих элементов к никелю, температуру испытания T и параметр Ларсона–Миллера P^*_{LM}. Входные признаки и целевая прочность стандартизировались. Параметры стандартизации вычислялись только по обучающей части соответствующего разбиения. Логарифмическое преобразование прочности не выполнялось.

На выборке для обучения и настройки проводилась пятикратная групповая кросс-валидация. На каждой итерации четыре блока использовались для обучения одной модели, а оставшийся блок — для валидации. Составы обучающей и валидационной частей не пересекались.

Обучение каждой модели состояло из двух этапов. Сначала выполнялось 1200 шагов детерминированного предобучения с функцией потерь Smooth L1. Затем проводилось байесовское обучение с ограничением в 8000 шагов.

Начиная с 600-го шага байесовского обучения, через каждые 200 шагов вычислялась среднеквадратичная ошибка на валидационной части в шкале МПа. При достаточном улучшении ошибки сохранялось состояние модели. Минимальное относительное улучшение составляло 0,1 %. Если улучшение отсутствовало в течение десяти последовательных проверок, обучение прекращалось. Для прогнозирования использовалось лучшее сохранённое состояние.

Для каждого фолда были получены прогнозы на его валидационной части. Их объединение сформировало OOF-прогнозы для всех 938 записей. При интерпретации этих результатов учитывалось, что валидационные данные использовались также для выбора момента остановки обучения, поэтому оценка могла быть оптимистичной.

Продолжительность финального байесовского обучения выбиралась как медиана лучших шагов, полученных на пяти фолдах. В выполненном эксперименте она составила 1200 шагов.

После этого семь новых моделей с различной случайной инициализацией обучались на всех 938 записях выборки для обучения и настройки. Каждая модель проходила 1200 шагов предобучения и 1200 шагов байесовского обучения. Параметры стандартизации на этом этапе вычислялись по всей указанной выборке.

Для каждой тестовой записи от каждой модели получали 500 значений выхода сети при выборках параметров из приближённого апостериорного распределения. После обратной стандартизации отрицательные значения ограничивались нулём. Итоговый прогноз определялся как медиана 3500 значений, объединённых по семи моделям.

Тестовые данные не участвовали в обучении весов, вычислении параметров стандартизации или выборе продолжительности обучения. Однако

эта тестовая выборка уже использовалась при разработке предыдущих вариантов модели, поэтому результат характеризует качество на фиксированном отложенном наборе, а не новую независимую внешнюю проверку.

Общая процедура включала следующие этапы:

1. Преобразование химического состава в атомные отношения элементов к никелю;
2. Формирование входов из признаков состава, температуры и параметра Ларсона–Миллера;
3. Групповое разделение данных на выборку для обучения и настройки и отложенный тест;
4. Пятикратную групповую кросс-валидацию со стандартизацией внутри каждого фолда, предобучением и байесовским обучением;
5. Выбор продолжительности финального обучения по результатам кросс-валидации;
6. Обучение семи новых моделей на всей выборке для обучения и настройки;
7. Получение итогового прогноза путём медианного объединения апостериорных выходов моделей;
8. Оценку качества на отложенных составах.

2.4.2 Критерии оценки качества

На байесовском этапе обучения минимизировалась отрицательная ELBO, описанная в разделе о модели. Для выбора лучшего состояния сети и контроля ранней остановки использовалась среднеквадратичная ошибка на валидационной части:

$$MSE = \frac{1}{n} \sum_{i=1}^{n} \left(\hat{\sigma}_i - \sigma_i \right)^2 , \tag{2.14}$$

где $\hat{\sigma}_i$ — прогнозируемая прочность, σ_i — экспериментальная прочность, а n — число оцениваемых наблюдений. Ошибки вычислялись после обратной стандартизации прогнозов, в исходной шкале прочности.

Для оценки итогового качества использовались средняя абсолютная ошибка:

$$MAE = \frac{1}{n} \sum_{i=1}^{n} \left| \hat{\sigma}_i - \sigma_i \right| \tag{2.15}$$

и корень из среднеквадратичной ошибки:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{\sigma}_i - \sigma_i)^2}. \tag{2.16}$$

Оба показателя выражаются в МПа.

Для оценки ошибок относительно экспериментального уровня прочности рассчитывалась относительная среднеквадратичная ошибка:

$$RRMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(\frac{\hat{\sigma}_i - \sigma_i}{\sigma_i}\right)^2}. \tag{2.17}$$

Этот показатель является безразмерным; для представления в процентах его умножают на 100.

Дополнительно вычислялся коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(\sigma_i - \hat{\sigma}_i)^2}{\sum_{i=1}^{n}(\sigma_i - \overline{\sigma})^2}, \tag{2.18}$$

где $\overline{\sigma}$ — средняя экспериментальная прочность в оцениваемой выборке.

Для отдельных наблюдений определялась абсолютная относительная ошибка:

$$RE_i = \frac{|\hat{\sigma}_i - \sigma_i|}{\sigma_i}. \tag{2.19}$$

По этим значениям рассчитывались медианная относительная ошибка и доли прогнозов с ошибкой не более 10 и 20 %.

2.5 Результаты моделирования

Качество модели оценивалось по объединённым валидационным прогнозам групповой кросс-валидации и на фиксированной отложенной тестовой выборке. Результаты представлены отдельно, поскольку они получены в разных условиях: на каждом фолде оценивалась одна модель, а на тесте — ансамбль из семи моделей.

2.5.1 Результаты групповой кросс-валидации

Для 938 записей выборки для обучения и настройки были получены OOF-прогнозы. Каждая запись прогнозировалась моделью, при обучении весов которой соответствующий состав не использовался.

Коэффициент детерминации составил $R^2 = 0{,}915$, средняя абсолютная ошибка — $MAE = 42{,}5$ МПа, а среднеквадратичная — $RMSE = 75{,}8$ МПа. Относительная среднеквадратичная ошибка составила $RRMSE = 0{,}291$, медианная относительная ошибка — 7,9 %. Ошибка не превышала 10 % для 58,6 % наблюдений и 20 % для 80,2 % наблюдений.

При интерпретации результатов следует учитывать, что валидационная часть каждого фолда также использовалась для выбора момента остановки обучения. Поэтому полученная оценка может быть оптимистичной.

2.5.2 Оценка точности на отложенной тестовой выборке

Итоговый ансамбль оценивался на 104 записях, соответствующих 49 составам, исключённым из обучения. Получены следующие показатели:

- коэффициент детерминации $R^2 = 0{,}959$;
- средняя абсолютная ошибка $MAE = 32{,}3$ МПа;
- среднеквадратичная ошибка $RMSE = 54{,}1$ МПа;
- относительная среднеквадратичная ошибка $RRMSE = 0{,}284$;
- медианная относительная ошибка — 5,6 %.

Относительная ошибка не превышала 10 % для 64,4 % тестовых наблюдений и 20 % для 82,7 % наблюдений.

Качество на отложенной выборке оказалось выше, чем по групповой кросс-валидации. Различие может быть связано как с особенностями исключённых составов, так и с использованием ансамбля и большего объёма данных при финальном обучении.

Поскольку эта тестовая выборка уже использовалась при разработке модели, полученные показатели характеризуют качество на фиксированном отложенном наборе. Они не являются результатом новой независимой внешней проверки.

2.5.3 Сопоставление прогнозов с экспериментальными данными

На рисунке 3 представлены результаты прогнозирования предельной прочности на отложенной тестовой выборке.

На диаграмме соответствия по оси абсцисс отложена экспериментальная прочность σ, а по оси ординат — прогнозируемая прочность $\hat{\sigma}$.

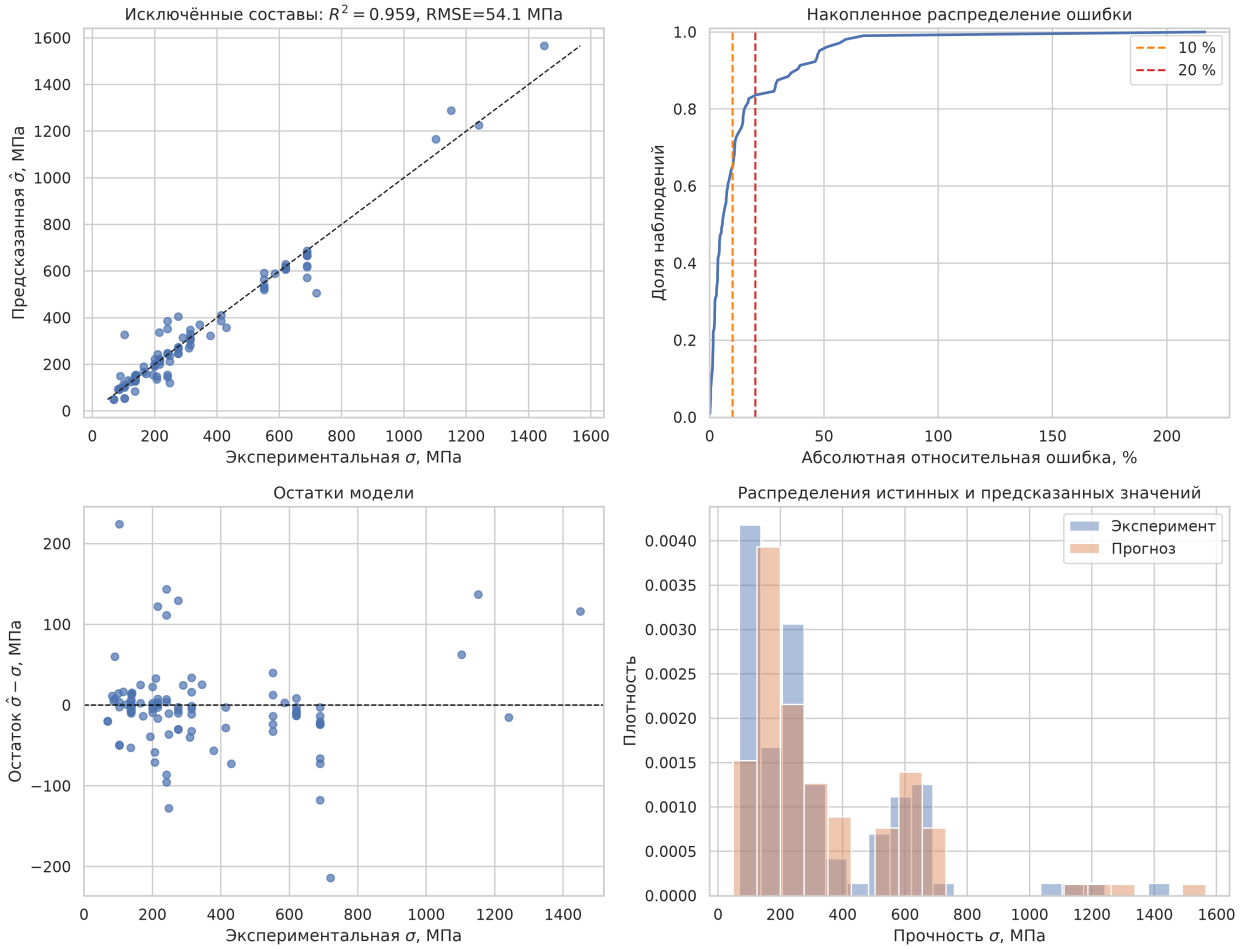


Рисунок 3 — Результаты прогнозирования на отложенной тестовой выборке: диаграмма соответствия экспериментальных и прогнозируемых значений (сверху слева), накопленное распределение относительной ошибки (сверху справа), остатки модели (снизу слева) и распределения значений прочности (снизу справа).

Штриховая линия соответствует точному совпадению прогноза и эксперимента.

Большинство точек расположено вблизи этой линии, однако для отдельных наблюдений сохраняются значительные отклонения. Это также видно на графике остатков $e_i = \hat{\sigma}_i - \sigma_i$. Положительные остатки соответствуют завышению прочности, отрицательные — её занижению.

Накопленное распределение абсолютной относительной ошибки показывает долю наблюдений, для которых ошибка не превышает заданного уровня. Ошибка не превышает 10 % для 64,4 % тестовых наблюдений и 20 % для 82,7 %.

Гистограммы экспериментальных и прогнозируемых значений имеют сходные области концентрации наблюдений, но отличаются по высоте

и положению отдельных пиков. Сходство распределений дополняет оценку качества, однако само по себе не подтверждает точность прогнозов для отдельных записей.

2.6 Выводы по главе

В данной главе реализована модель прогнозирования предельной прочности никелевых суперсплавов на основе байесовской нейронной сети. Работа выполнена по мотивам подхода, представленного в статье [2], с изменениями архитектуры, процедуры обучения и проверки качества.

Основные результаты заключаются в следующем:

– В качестве входов использованы 26 атомных отношений легирующих элементов к никелю, температура испытания и параметр Ларсона–Миллера;

– Целевая прочность стандартизировалась без логарифмического преобразования. Итоговые прогнозы переводились в МПа;

– Разделение данных выполнялось по группам химического состава, что исключало попадание одного состава одновременно в обучающую и проверочную части;

– Реализован ансамбль из семи байесовских нейронных сетей с архитектурой скрытых слоёв 48–24–12;

– По объединённым прогнозам групповой кросс-валидации получены $R^2 = 0{,}915$, $MAE = 42{,}5$ МПа и $RMSE = 75{,}8$ МПа;

– На отложенной тестовой выборке получены $R^2 = 0{,}959$, $MAE = 32{,}3$ МПа и $RMSE = 54{,}1$ МПа. Медианная относительная ошибка составила 5,6 %.

Полученные результаты показывают возможность прогнозирования предельной прочности по составу и условиям испытания в пределах рассмотренного набора данных. При этом для отдельных наблюдений сохраняются значительные ошибки.

Оценки качества имеют методические ограничения: валидационные фолды использовались для выбора момента остановки обучения, а отложенная тестовая выборка ранее рассматривалась при разработке модели. Для дополнительного подтверждения обобщающей способности необходима проверка на новом внешнем наборе данных.

ЗАКЛЮЧЕНИЕ

Таким образом, в процессе выполнения работы были решены следующие задачи:

– Была изучена и реализована модель обучения с дифференциальным слоем. В ходе численного эксперимента подтверждено, что данная архитектура позволяет эффективно прогнозировать температуру сольвуса с высокой точностью, что решает первую поставленную задачу.

– Для прогнозирования предела прочности была обучена байесовская регуляризованная нейронная сеть (BRANN).

– Проведенный сравнительный анализ показал, что воспроизведенные модели демонстрируют результаты, сопоставимые с оригинальными данными из научных статей, что подтверждает их адекватность и применимость в задачах материаловедения.

В пути дальнейшей работы входит донастройка параметров сети и/или проба другой арихитектуры нейронной сети.

Таким образом, поставленная цель работы достигнута. Результаты исследования демонстрируют высокий потенциал методов искусственного интеллекта для ускорения разработки и оптимизации состава жаропрочных никелевых суперсплавов.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

1. *Dmitry Tarasov Andrey Tyagunov*, *O. M.* Simulation of the nickel superalloys solvus temperature by the deep learning artificial neural network with differential layer / O. M. Dmitry Tarasov Andrey Tyagunov. — 2022.

2. *Dmitry Tarasov Andrey Tyagunov*, *O. M.* BRANN forecast of superalloy tensile strength versus Larson–Miller parameter relation and its approximation by a sigmoidal function / O. M. Dmitry Tarasov Andrey Tyagunov. — 2022.