

Министерство науки и высшего образования Российской Федерации
ФГАОУ ВО «УрФУ имени первого Президента России Б.Н. Ельцина»
Кафедра «Вычислительной математики и компьютерных наук»

Оценка работы _____
Шека Андрей Сергеевич

Применение искусственных нейронных сетей для анализа фазовых переходов
и механических свойств никелевых суперсплавов

ОТЧЕТ
Учебная практика

Руководитель практики от предприятия (организации) - Шека А. С.
ФИО руководителя Подпись

Студент Эсаулов Н.В.
ФИО студента

Специальность (направление подготовки) 02.04.01 Математика и компьютерные
науки

Группа МЕНМ-150201

Екатеринбург 2026

РЕФЕРАТ

Настоящая работа посвящена воспроизведению и анализу методов нейросетевого моделирования свойств никелевых жаропрочных сплавов. Рассмотрены две задачи: прогнозирование температуры сольвуса γ' -фазы по химическому составу сплава и моделирование зависимости прочности никелевых суперсплавов от параметра Ларсона–Миллера.

В первой части работы исследуется подход к прогнозированию температуры сольвуса с использованием искусственной нейронной сети с дифференциальным слоем. Особое внимание уделено подготовке входных данных: учету априорной информации о физической роли элементов в структуре жаропрочных сплавов. Такой подход позволяет представить состав сплава в более физически обоснованной форме и повысить интерпретируемость модели.

Во второй части рассматривается модель прогнозирования жаропрочности никелевых суперсплавов на основе байесовской регуляризованной искусственной нейронной сети BRANN. В качестве входных признаков используются химический состав и нормированный параметр Ларсона–Миллера, объединяющий температуру и время испытания. Для повышения устойчивости обучения прочность предварительно преобразуется в логарифмическую форму.

В работе описаны теоретические основы, подготовка данных, структура применяемых нейронных сетей, особенности реализации вычислительных экспериментов и основные результаты моделирования. Показано, что использование методов машинного обучения позволяет учитывать сложные нелинейные зависимости между химическим составом, температурно-временными условиями и свойствами никелевых жаропрочных сплавов.

Ключевые слова: никелевые жаропрочные сплавы, суперсплавы, температура сольвуса, γ' -фаза, искусственная нейронная сеть, дифференциальный слой, BRANN, байесовская регуляризация, параметр Ларсона–Миллера, жаропрочность.

СОДЕРЖАНИЕ

Словарь терминов

Никелевые жаропрочные сплавы - сложнолегированные металлические материалы на основе никеля, предназначенные для работы при высоких температурах, длительных нагрузках и в агрессивных средах. Характеризуются высокой жаропрочностью, коррозионной стойкостью и структурной стабильностью.

Суперсплавы - класс высоколегированных сплавов, сохраняющих механические свойства при температурах, близких к температуре плавления. В данной работе под суперсплавами преимущественно понимаются никелевые жаропрочные сплавы.

γ -матрица - основная фаза никелевых жаропрочных сплавов, представляющая собой твердый раствор на основе никеля с гранецентрированной кубической решеткой. В γ -матрице распределены упрочняющие фазы.

γ' -фаза - упрочняющая интерметаллидная фаза, она является одним из основных факторов высокой жаропрочности никелевых суперсплавов.

γ'' -фаза - упрочняющая метастабильная интерметаллидная фаза, характерная для некоторых никелевых сплавов, содержащих ниобий. Вносит вклад в повышение прочности, особенно при промежуточных температурах.

Температура сольвуса - температура, выше которой определенная фаза полностью растворяется в матрице сплава. В данной работе особое значение имеет температура сольвуса γ' -фазы, обозначаемая как T_{solvus} .

T_{solvus} - обозначение температуры сольвуса. Используется как целевая переменная при моделировании фазовой стабильности никелевых суперсплавов.

Легирование - введение в сплав дополнительных химических элементов с целью изменения его структуры и свойств. В никелевых суперсплавах легирование используется для повышения прочности, жаростойкости, коррозионной стойкости и фазовой стабильности.

Параметр Ларсона–Миллера - температурно-временной параметр, объединяющий температуру и время выдержки или разрушения:

$$P_{LM} = T(C + \log_{10} \tau).$$

Используется для описания длительной прочности и деградации материала при высоких температурах.

P_{LM}^* нормированная форма параметра Ларсона–Миллера:

$$P_{LM}^* = T(20 + \log_{10} \tau) \cdot 10^{-5}.$$

Нормировка используется для согласования масштаба данного параметра с концентрациями элементов во входном векторе нейронной сети.

Предел прочности - максимальное механическое напряжение, которое материал выдерживает до разрушения. Обозначается как σ .

σ - обозначение прочности или предела прочности сплава. В одной из моделей является целевой переменной, предсказываемой нейронной сетью.

Многослойный персептрон - тип нейронной сети прямого распространения, состоящий из входного слоя, одного или нескольких скрытых слоев и выходного слоя.

Скрытый слой - внутренний слой нейронной сети, в котором выполняется нелинейное преобразование входных данных.

Выходной слой - последний слой нейронной сети, формирующий итоговое предсказание модели.

Функция активации - нелинейная функция, применяемая к выходу нейрона. Позволяет нейронной сети моделировать нелинейные зависимости.

Обучение нейронной сети - процесс подбора весов и смещений сети с целью минимизации ошибки между предсказанными и экспериментальными значениями.

Обратное распространение ошибки - алгоритм вычисления градиентов ошибки по параметрам нейронной сети, используемый при ее обучении.

Переобучение - ситуация, при которой модель слишком хорошо запоминает обучающую выборку, но плохо предсказывает новые данные.

Регуляризация - метод ограничения сложности модели для уменьшения переобучения и повышения обобщающей способности.

BRANN - Bayesian Regularized Artificial Neural Network — искусственная нейронная сеть с байесовской регуляризацией. Используется для повышения устойчивости модели к переобучению.

Бутстреп - метод многократного случайного формирования обучающих и проверочных выборок из исходных данных. Используется для повышения надежности оценки модели.

Обучающая выборка - часть данных, используемая для настройки параметров модели.

Валидационная выборка - часть данных, используемая для контроля качества модели во время обучения и предотвращения переобучения.

Тестовая выборка - независимая часть данных, используемая для окончательной оценки качества обученной модели.

Априорная информация - заранее известные сведения о физической природе объекта моделирования. В данной работе это информация о роли легирующих элементов в структуре и свойствах суперсплавов.

Матрица связей - матрица, описывающая принадлежность легирующих элементов к различным группам влияния. Используется для внедрения физической информации в архитектуру нейронной сети.

Дифференциальный слой - слой нейронной сети, передающий информацию о чувствительности выходного параметра к изменению входных признаков.

MSE - Mean Squared Error — среднеквадратичная ошибка:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

RMSE - Root Mean Squared Error — корень из среднеквадратичной ошибки. В отчете также используется относительная форма RMSE для оценки ошибки прогноза прочности.

RMAE - Relative Mean Absolute Error — относительная средняя абсолютная ошибка. Используется для оценки точности прогноза температуры сольвуса.

RRMSE - Relative Root Mean Squared Error — относительная среднеквадратичная ошибка. Используется для оценки качества модели при прогнозировании температуры сольвуса.

Химический состав - совокупность концентраций элементов, входящих в сплав. В моделях машинного обучения химический состав используется как входной вектор признаков.

Вектор признаков - набор численных характеристик объекта, передаваемый на вход модели. Для суперсплавов включает концентрации легирующих элементов и, при необходимости, параметр Ларсона–Миллера.

Целевая переменная - величина, которую необходимо предсказать с помощью модели. В данном отчете целевыми переменными являются температура сольвуса T_{solvus} и прочность σ .

ВВЕДЕНИЕ

Актуальность. В современной промышленности и материаловедении никелевые суперсплавы играют критически важную роль, особенно в авиастроении и энергетике, где требуются материалы, способные выдерживать экстремальные температуры и механические нагрузки. Традиционные методы подбора состава и прогнозирования свойств таких сплавов требуют проведения дорогостоящих и длительных физических экспериментов. В связи с этим, применение методов машинного обучения и искусственных нейронных сетей для ускорения процесса разработки новых материалов является высокоактуальной задачей.

Проблема. Несмотря на наличие больших массивов экспериментальных данных, классические эмпирические модели и физические уравнения часто не способны точно описать сложные нелинейные зависимости между химическим составом суперсплавов, параметрами термической обработки и их итоговыми физико-механическими свойствами. Это приводит к высокой погрешности прогнозов и необходимости многократного перебора вариантов при создании новых марок сплавов.

Целью работы является численное воспроизведение и анализ современных подходов к прогнозированию термических и механических свойств никелевых суперсплавов с использованием архитектур глубокого обучения и байесовских нейронных сетей.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Изучить и воспроизвести модель глубокого обучения с дифференциальным слоем для прогнозирования температуры сольвуса никелевых суперсплавов.
2. Реализовать байесовскую регуляризованную нейронную сеть (BRANN) для прогнозирования предела прочности суперсплавов в зависимости от параметра Ларсона-Миллера.
3. Провести сравнительный анализ точности полученных нейросетевых моделей с оригинальными данными из научных статей.

Краткое содержание и результаты. В ходе выполнения работы был предобработан датасет, описывающий химический состав и свойства никелевых суперсплавов. Были реализованы две нейросетевые архитекту-

ры. В результате воспроизведения первой модели удалось достичь высокой точности предсказания температуры сольвуса. Во второй части работы с помощью BRANN удалось частично аппроксимирована зависимость предела прочности от параметра Ларсона-Миллера, но оптимальные параметры не были подобраны. Полученные результаты подтверждают эффективность применения методов машинного обучения в физике металлов.

«««< HEAD

1 Моделирование температуры сольвуса никелевых жаропрочных сплавов с использованием нейронной сети

=====

2 Моделирование температуры сольвуса никелевых жаропрочных сплавов с использованием нейронной сети

»»»> master

2.1 Теоретические основы

2.1.1 Никелевые жаропрочные сплавы и температура сольвуса

«««< HEAD Никелевые жаропрочные сплавы представляют собой сложнолегированные металлические материалы, предназначенные для работы при высоких температурах, механических нагрузках и агрессивных средах. Их высокая жаропрочность обусловлена многофазной структурой и наличием упрочняющих выделений, главным образом фаз γ' и γ'' . Основой большинства никелевых суперсплавов является γ -матрица на основе никеля. В ней распределены частицы упрочняющей γ' -фазы. Также в зависимости от состава могут присутствовать карбиды, бориды и другие интерметаллидные соединения.

Одним из важнейших параметров, характеризующих фазовую стабильность никелевого жаропрочного сплава, является температура сольвуса γ' -фазы T_{solvus} . Температура сольвуса соответствует температуре, выше которой упрочняющая фаза начинает растворяться в матрице. При превышении этой температуры структура сплава теряет устойчивость, что приводит к снижению прочностных характеристик.

Следовательно, прогнозирование температуры сольвуса по химическому составу является важной задачей при разработке новых жаропрочных сплавов и оптимизации уже существующих композиций.

2.1.2 Влияние легирующих элементов

Химический состав никелевых жаропрочных сплавов может включать большое количество элементов: Th, C, Cr, Co, Mo, W, Al, Ti, Nb, V, Fe, Y, Zr, Ta, Re, Ru, V, La, S, Si, Mn, P, Hf, Cu, Ge, Ga, Ni. Каждый из них выполняет определенную функцию.

Например, элементы Al, Ti, Ta и Nb участвуют в образовании упрочняющих интерметаллидных фаз. Cr и Al повышают стойкость к окислению

и коррозии. Co, Mo, W, Re и Ta могут упрочнять твердый раствор. C, B, Zr и Hf влияют на границы зерен и образование карбидных фаз.

Влияние легирующих элементов является существенно нелинейным. Кроме того, один и тот же элемент может одновременно участвовать в нескольких физических механизмах. Поэтому построение простой аналитической зависимости между химическим составом и температурой сольвуса является затруднительным. ===== Никелевые жаропрочные сплавы представляют собой сложнолегированные металлические материалы, предназначенные для работы при высоких температурах, механических нагрузках и агрессивных средах. Их высокая жаропрочность обусловлена многофазной структурой и наличием упрочняющих выделений, главным образом фаз γ' и γ'' . Основой большинства никелевых суперсплавов является γ -матрица на основе никеля. В ней распределены частицы упрочняющей γ' -фазы. Также в зависимости от состава могут присутствовать карбиды, бориды и другие интерметаллидные соединения.

Одним из важнейших параметров, характеризующих фазовую стабильность никелевого жаропрочного сплава, является температура сольвуса γ' -фазы T_{solvus} . Температура сольвуса соответствует температуре, выше которой упрочняющая фаза начинает растворяться в матрице. При превышении этой температуры структура сплава теряет устойчивость, что приводит к снижению прочностных характеристик.

Следовательно, прогнозирование температуры сольвуса по химическому составу является важной задачей при разработке новых жаропрочных сплавов и оптимизации уже существующих композиций.

2.1.3 Влияние легирующих элементов

Химический состав никелевых жаропрочных сплавов может включать большое количество элементов: Th, C, Cr, Co, Mo, W, Al, Ti, Nb, B, Fe, Y, Zr, Ta, Re, Ru, V, La, S, Si, Mn, P, Hf, Cu, Ge, Ga, Ni. Каждый из них выполняет определенную функцию.

Например, элементы Al, Ti, Ta и Nb участвуют в образовании упрочняющих интерметаллидных фаз. Cr и Al повышают стойкость к окислению и коррозии. Co, Mo, W, Re и Ta могут упрочнять твердый раствор. C, B, Zr и Hf влияют на границы зерен и образование карбидных фаз.

Влияние легирующих элементов является существенно нелинейным. Кроме того, один и тот же элемент может одновременно участвовать в нескольких физических механизмах. Поэтому построение простой аналитической зависимости между химическим составом и температурой сольвуса является затруднительным. »»»> master

2.2 Описание модели

2.2.1 Нейронная сеть

«««< HEAD Для прогнозирования температуры сольвуса используется искусственная нейронная сеть прямого распространения. В общем виде модель можно записать следующим образом: ===== Для прогнозирования температуры сольвуса используется искусственная нейронная сеть прямого распространения. В общем виде модель можно записать следующим образом: »»»> master

$$\hat{T}_{\text{solvus}} = f_{\theta}(x_1, x_2, \dots, x_m), \quad (2.1)$$

«««< HEAD где $\hat{T}_{\text{solvus}}$ — предсказанное значение температуры сольвуса, x_i — процентное содержание легирующего элемента, θ — обучаемые параметры модели.

Нейронная сеть выполняет роль нелинейного аппроксиматора, который устанавливает зависимость между химическим составом и температурой сольвуса. Преимущество такого подхода заключается в способности учитывать сложные нелинейные взаимодействия между элементами, которые трудно описать классическими аналитическими выражениями.

2.2.2 Учет априорной физической информации

Особенностью рассматриваемой модели является включение в архитектуру сети априорной информации о роли легирующих элементов. Элементы группируются по их влиянию на свойства сплава: твердорастворное упрочнение, образование карбидов, формирование γ' -фазы, повышение стойкости к окислению, стабилизация границ зерен и т.д. ===== где $\hat{T}_{\text{solvus}}$ — предсказанное значение температуры сольвуса, x_i — процентное содержание легирующего элемента, θ — обучаемые параметры модели.

Нейронная сеть выполняет роль нелинейного аппроксиматора, который устанавливает зависимость между химическим составом и температурой сплавов. Преимущество такого подхода заключается в способности учитывать сложные нелинейные взаимодействия между элементами, которые трудно описать классическими аналитическими выражениями.

2.2.3 Учет априорной физической информации

Особенностью рассматриваемой модели является включение в архитектуру сети априорной информации о роли легирующих элементов. Элементы группируются по их влиянию на свойства сплава: твердорастворное упрочнение, образование карбидов, формирование γ' -фазы, повышение стойкости к окислению, стабилизация границ зерен и т.д. $\gg\gg\gg$ master

Эта информация может быть представлена в виде матрицы связей:

$$R = [r_{gi}], \quad (2.2)$$

$\gg\gg\gg$ HEAD где r_{gi} показывает, относится ли элемент i к группе влияния g . Если элемент входит в соответствующую группу, то $r_{gi} = 1$, иначе $r_{gi} = 0$. $\gg\gg\gg$ где r_{gi} показывает, относится ли элемент i к группе влияния g . Если элемент входит в соответствующую группу, то $r_{gi} = 1$, иначе $r_{gi} = 0$. $\gg\gg\gg$ master

Для каждой группы можно сформировать обобщенный сигнал:

$$s_g = \sum_{i=1}^m r_{gi} x_i, \quad (2.3)$$

где s_g — суммарный вклад элементов, относящихся к g -й группе.

$\gg\gg\gg$ HEAD Таким образом, нейронная сеть получает не только численные концентрации элементов, но и информацию об их физической роли в структуре сплава. $\gg\gg\gg$ Таким образом, нейронная сеть получает не только численные концентрации элементов, но и информацию об их физической роли в структуре сплава. $\gg\gg\gg$ master

2.2.4 Дифференцирующий слой

Дифференцирующий слой формирует два нелинейных преобразования входного сигнала группы: «»»< HEAD

$$\mathbf{p}_g = \tanh(W_g^+ \mathbf{x}_g + \mathbf{b}_g^+),$$

$$\mathbf{n}_g = \tanh(W_g^- \mathbf{x}_g + \mathbf{b}_g^-),$$

где W_g^+ и W_g^- — обучаемые матрицы весов, а $\mathbf{b}_g^+$ и $\mathbf{b}_g^-$ — векторы смещений. В данной модели смещениям установлены значения

$$\mathbf{b}_g^+ = 0.5, \quad \mathbf{b}_g^- = -0.5.$$

Дифференцированный сигнал определяется как разность двух нелинейных преобразований:

$$\mathbf{d}_g = \mathbf{p}_g - \mathbf{n}_g.$$

=====

$$\mathbf{p}_g = \tanh(W_g^+ \mathbf{x}_g + \mathbf{b}_g^+),$$

$$\mathbf{n}_g = \tanh(W_g^- \mathbf{x}_g + \mathbf{b}_g^-),$$

где W_g^+ и W_g^- — обучаемые матрицы весов, а $\mathbf{b}_g^+$ и $\mathbf{b}_g^-$ — векторы смещений. В данной модели смещениям установлены значения

$$\mathbf{b}_g^+ = 0.5, \quad \mathbf{b}_g^- = -0.5.$$

Дифференцированный сигнал определяется как разность двух нелинейных преобразований:

$$\mathbf{d}_g = \mathbf{p}_g - \mathbf{n}_g.$$

»»»> master Такое представление позволяет сети учитывать не только суммарное содержание элементов в группе, но и различия в характере их влияния на целевое свойство.

Выход g -й ветви дифференцирующего слоя записывается в виде «»»< HEAD

$$\mathbf{h}_g = [s_g, \mathbf{p}_g, \mathbf{n}_g, \mathbf{d}_g].$$

После обработки всех групп выходные векторы объединяются:

$$\mathbf{h} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_G],$$

=====

$$\mathbf{h}_g = [s_g, \mathbf{p}_g, \mathbf{n}_g, \mathbf{d}_g].$$

После обработки всех групп выходные векторы объединяются:

$$\mathbf{h} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_G],$$

»»»> master где G — число групп легирующих элементов.

Итоговый вход последующей полносвязной части сети формируется путем объединения исходного вектора состава и группового дифференцированного сигнала: «««< HEAD

$$\mathbf{z} = [\mathbf{x}, \mathbf{h}].$$

Затем вектор $\mathbf{z}$ поступает на полносвязную нейронную сеть:

$$\hat{y} = f_{\theta}(\mathbf{z}),$$

=====

$$\mathbf{z} = [\mathbf{x}, \mathbf{h}].$$

Затем вектор $\mathbf{z}$ поступает на полносвязную нейронную сеть:

$$\hat{y} = f_{\theta}(\mathbf{z}),$$

»»»> master где $\hat{y}$ — прогнозируемое значение температуры сольвуса, а f_{θ} — обучаемая нелинейная функция, реализуемая скрытыми слоями нейронной сети.

Таким образом, дифференцирующий слой выполняет две функции. Во-первых, он внедряет в архитектуру сети априорную информацию о физической роли легирующих элементов. Во-вторых, он формирует дополнительные нелинейные признаки, описывающие групповой и дифференцированный вклад элементов в прогнозируемое свойство.

2.3 Реализация модели

2.3.1 Общая схема вычислительного эксперимента

Реализация модели включает следующие этапы:

«««< HEAD формирование матрицы связей, описывающей физическую роль легирующих элементов; ===== формирование матрицы связей, описывающей физическую роль легирующих элементов; »»»> master построение глубокой нейронной сети с дифференциальным слоем; обучение модели на подготовленных данных; оценка точности прогноза по выбранным метрикам.

2.3.2 Метрики качества

«««< HEAD Для оценки качества прогноза могут использоваться относительная средняя абсолютная ошибка и относительная среднеквадратичная ошибка. ===== Для оценки качества прогноза могут использоваться относительная средняя абсолютная ошибка и относительная среднеквадратичная ошибка. »»»> master

Относительная средняя абсолютная ошибка определяется выражением:

$$RMAE = \frac{1}{n} \sum_{i=1}^n \left| \frac{T_i - \hat{T}_i}{T_i} \right| \cdot 100\%, \quad (2.4)$$

где T_i — экспериментальное значение температуры сольвуса, $\hat{T}_i$ — предсказанное значение, n — количество объектов в выборке.

Относительная среднеквадратичная ошибка определяется как:

$$RRMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n \left(\frac{T_i - \hat{T}_i}{T_i} \right)^2}. \quad (2.5)$$

2.4 Результаты моделирования

В результате применения нейронной сети была получена модель, способная прогнозировать температуру сольвуса никелевых жаропрочных

сплавов по их химическому составу. Использование априорной информации о роли элементов позволило повысить физическую обоснованность входных данных.

По данным воспроизводимой статьи, модель показала достаточно высокую точность: относительная средняя абсолютная ошибка составила около $RMAE = 5.89\%$, а относительная среднеквадратичная ошибка — около $RRMSE = 0.09$.

2.4.1 Точечные результаты на тестовой выборке

На тестовой выборке были получены предсказания $\hat{y}$ и вычислены ошибки. Для иллюстрации качества работы модели в таблице приведены 5 случаев с наибольшими значениями ошибки на тесте.

y_{true}	y_{pred}	$ e $	$rel_error(\%)$
«««< HEAD ...	...	...	...
...	...	...	...
...	...	...	...
...	...	...	...
...	...	...	...

2.4.2 Оценка качества модели по кросс-валидации

Для проверки устойчивости обучения использовалась кросс-валидация: модель переобучалась на каждом фолде и вычислялись метрики.

=====	773.15	1191.20	418.05	54.07
-----	973.15	1285.83	312.68	32.13
-----	1023.15	1224.65	201.50	19.69
-----	1373.15	1154.06	219.08	15.95
-----	1143.15	967.36	175.78	15.37

2.4.3 Оценка качества модели по кросс-валидации

Для проверки устойчивости обучения использовалась кросс-валидация: модель переобучалась на каждом фолде и вычислялись метрики. »»»> master Итоговые значения представлены медианой и дисперсией по фолдам.

«««< HEAD

Таблица 1 — Сводные результаты кросс-валидации (медиана и дисперсия)
===== »»»> master

Метрика	Медиана	Дисперсия
«««< HEAD RRMAE (%)	...	...
RRMSE	...	...

2.4.4 Неопределённость метрик по методу бутстрэпа

Для дополнительно оценки устойчивости метрик вычислялись распределения RRMAE и RRMSE с помощью бутстрэпа. Квантили 2.5% и 97.5% соответствуют приближённому доверительному интервалу, а вертикальная линия (медиана) показывает центральную тенденцию. Рисунки ??-?? иллюстрируют полученные распределения. ===== RRMAE (%) 4.36 0.79 RRMSE 0.08 0.0001

2.4.5 Неопределённость метрик по методу бутстрэпа

Для дополнительно оценки устойчивости метрик вычислялись распределения RRMAE и RRMSE с помощью бутстрэпа. Квантили 2.5% и 97.5% соответствуют приближённому доверительному интервалу, а вертикальная линия (медиана) показывает центральную тенденцию. Рисунки ??-?? иллюстрируют полученные распределения. »»»> master

«««< HEAD

2.5 Выводы по главе

Полученные результаты показывают, что нейронная сеть с дифференциальным слоем может быть использована для прогнозирования




Рисунок 1 — Распределение RRMAE (%) по бутстрэп-выборкам




Рисунок 2 — Распределение RRMSE по бутстрэп-выборкам

температуры сольвуса сложнолегированных никелевых суперсплавов. Такой подход особенно эффективен в условиях, когда аналитическое описание зависимости между составом и свойствами затруднено из-за высокой нелинейности и многокомпонентности системы.

В данной главе рассмотрен подход к моделированию температуры сольвуса никелевых жаропрочных сплавов с использованием глубокой нейронной сети. Основными особенностями модели являются: =====
Итак, таблица ?? показывает поведение модели на тесте в наиболее проблемных случаях, кросс-валидация (табл. ??) оценивает устойчивость качества при повторном обучении на различных фолдах, а бутстрэп

(рис. ??–??) предоставляет распределения метрик и их доверительные интервалы.

2.6 Выводы по главе

Полученные результаты показывают, что нейронная сеть с дифференциальным слоем может быть использована для прогнозирования температуры сольвуса сложнолегированных никелевых суперсплавов. Такой подход особенно эффективен в условиях, когда аналитическое описание зависимости между составом и свойствами затруднено из-за высокой нелинейности и многокомпонентности системы.

Основными особенностями модели являются: »»»> master

1. 2. 3. 4. 5. – учет физической роли легирующих элементов;

– применение дифференциального слоя для анализа чувствительности модели.

«««< HEAD Итак, таблица ?? показывает поведение модели на тесте в наиболее проблемных случаях, кросс-валидация (табл. ??) оценивает устойчивость качества при повторном обучении на различных фолдах, а бутстрэп (рис. ??–??) предоставляет распределения метрик и их доверительные интервалы.

3 Прогнозирование жаропрочности никелевых суперсплавов с использованием BRANN и параметра Ларсона–Миллера

=====

4 Прогнозирование жаропрочности никелевых суперсплавов с использованием BRANN и параметра Ларсона–Миллера

»»»> master

4.1 Теоретические основы

4.1.1 Жаропрочность никелевых суперсплавов

«««< HEAD Жаропрочность является одной из ключевых характеристик никелевых суперсплавов. Она определяет способность материала сохранять прочность при длительном воздействии высокой температуры и механической нагрузки.

В условиях высокотемпературной эксплуатации структура суперсплава постепенно деградирует. Происходит укрупнение упрочняющих фаз, изменение морфологии выделений, перераспределение легирующих элементов и накопление повреждений. В результате предел прочности σ снижается.

Для описания изменения прочности при различных температурах и временах выдержки удобно использовать обобщенные температурно-временные параметры. Одним из наиболее распространенных является параметр Ларсона–Миллера.

4.1.2 Параметр Ларсона–Миллера

Параметр Ларсона–Миллера объединяет температуру и время выдержки в одну величину: ===== Жаропрочность является одной из ключевых характеристик никелевых суперсплавов. Она определяет способность материала сохранять прочность при длительном воздействии высокой температуры и механической нагрузки.

В условиях высокотемпературной эксплуатации структура суперсплава постепенно деградирует. Происходит укрупнение упрочняющих фаз, изменение морфологии выделений, перераспределение легирующих элементов и накопление повреждений. В результате предел прочности σ снижается.

Для описания изменения прочности при различных температурах и временах выдержки удобно использовать обобщенные температурно-временные параметры. Одним из наиболее распространенных является параметр Ларсона–Миллера.

4.1.3 Параметр Ларсона–Миллера

Параметр Ларсона–Миллера объединяет температуру и время выдержки в одну величину: $P_{LM} = T(20 + \log_{10} \tau)$

$$P_{LM} = T(20 + \log_{10} \tau), \quad (4.1)$$

где T — температура испытания, τ — время выдержки или длительность испытания. $P_{LM}^* = T(20 + \log_{10} \tau) \cdot 10^{-5}$ где T — температура испытания, τ — время выдержки или длительность испытания.

В рассматриваемой работе используется нормированная форма параметра:

$$P_{LM}^* = T(20 + \log_{10} \tau) \cdot 10^{-5}. \quad (4.2)$$

Нормировка необходима для того, чтобы значения параметра Ларсона–Миллера были сопоставимы по порядку величины с концентрациями легирующих элементов, используемыми как входные признаки нейронной сети.

Параметр P_{LM}^* отражает степень температурно-временного воздействия на материал. При увеличении этого параметра прочность сплава, как правило, снижается вследствие термической деградации структуры. Нормировка необходима для того, чтобы значения параметра Ларсона–Миллера были сопоставимы по порядку величины с концентрациями легирующих элементов, используемыми как входные признаки нейронной сети.

Параметр P_{LM}^* отражает степень температурно-временного воздействия на материал. При увеличении этого параметра прочность сплава, как правило, снижается вследствие термической деградации структуры.

4.2 Исходные данные

4.2.1 Структура базы данных

«««< HEAD Для обучения модели использовалась база данных никелевых суперсплавов, содержащая сведения о химическом составе и результатах механических испытаний. ===== Для обучения модели использовалась база данных никелевых суперсплавов, содержащая сведения о химическом составе и результатах механических испытаний. »»»> master

В качестве входных признаков использовались содержания легирующих элементов:

$$\mathbf{x} = (c_1, c_2, \dots, c_m, P_{LM}^*), \quad (4.3)$$

«««< HEAD где c_i — концентрация i -го легирующего элемента, m — количество учитываемых элементов. ===== где c_i — концентрация i -го легирующего элемента, m — количество учитываемых элементов. »»»> master

В базе данных учитывались следующие элементы:

$$\begin{aligned} &\text{Th, C, Cr, Co, Mo, W, Al, Ti, Nb, V, Fe, Y, Zr, Ta,} \\ &\text{Re, Ru, V, La, S, Si, Mn, P, Hf, Cu, Ge, Ga, Ni} \end{aligned} \quad (4.4)$$

«««< HEAD Всего база содержала 1049 отдельную запись, каждая из которых соответствовала конкретному химическому составу и определенному условию испытания.

4.2.2 Целевая переменная

Целевой переменной являлась прочность σ при заданных условиях температурно-временного воздействия. Так как значения прочности могут изменяться в широком диапазоне, перед обучением применялось логарифмическое преобразование: ===== Всего база содержала 1049 отдельную запись, каждая из которых соответствовала конкретному химическому составу и определенному условию испытания.

4.2.3 Целевая переменная

Целевой переменной являлась прочность σ при заданных условиях температурно-временного воздействия. Так как значения прочности могут изменяться в широком диапазоне, перед обучением применялось логарифмическое преобразование: $y = -\log_{10} \sigma$

$$y = -\log_{10} \sigma. \quad (4.5)$$

Обратное преобразование выполнялось по формуле:

$$\sigma = 10^{-y}. \quad (4.6)$$

« $\ll$ »< HEAD Такое преобразование позволяет уменьшить влияние больших значений прочности на процесс обучения, а также исключает появление отрицательных значений прочности после обратного преобразования. ===== Такое преобразование позволяет уменьшить влияние больших значений прочности на процесс обучения, а также исключает появление отрицательных значений прочности после обратного преобразования. $\gg$ »> master

4.3 Описание модели BRANN

4.3.1 Байесовская регуляризованная нейронная сеть

Для прогнозирования прочности использовалась байесовская регуляризованная искусственная нейронная сеть BRANN. Она является разновидностью многослойного персептрона, в котором обучение сопровождается регуляризацией весовых коэффициентов.

В общем виде прогноз модели записывается как:

$$\hat{y} = f_{\theta}(c_1, c_2, \dots, c_m, P_{LM}^*), \quad (4.7)$$

« $\ll$ »< HEAD где $\hat{y}$ — предсказанное значение логарифмически преобразованной прочности, θ — параметры нейронной сети.

Байесовская регуляризация используется для уменьшения риска переобучения. При обучении минимизируется функционал: ===== где $\hat{y}$ — предсказанное значение логарифмически преобразованной прочности, θ — параметры нейронной сети.

Байесовская регуляризация используется для уменьшения риска переобучения. При обучении минимизируется функционал: »»»> master

$$F = \beta E_D + \alpha E_W, \quad (4.8)$$

«««< HEAD где E_D — ошибка на обучающих данных, E_W — сумма квадратов весов сети, α и β — параметры регуляризации. ===== где E_D — ошибка на обучающих данных, E_W — сумма квадратов весов сети, α и β — параметры регуляризации. »»»> master

Ошибка на данных определяется как:

$$E_D = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (4.9)$$

Регуляризационный член имеет вид:

$$E_W = \sum_j w_j^2, \quad (4.10)$$

где w_j — весовые коэффициенты нейронной сети.

4.3.2 Архитектура нейронной сети

«««< HEAD В рассматриваемой работе использовалась сеть с одним скрытым слоем. Входной слой содержал признаки химического состава и параметр Ларсона–Миллера. Скрытый слой включал 10 нейронов. Выходной слой состоял из одного нейрона, выдающего значение $\hat{y}$. ===== В рассматриваемой работе использовалась сеть с одним скрытым слоем. Входной слой содержал признаки химического состава и параметр Ларсона–Миллера. Скрытый слой включал 10 нейронов. Выходной слой состоял из одного нейрона, выдающего значение $\hat{y}$. »»»> master

Схематично модель можно представить следующим образом:

$$(c_1, c_2, \dots, c_m, P_{LM}^*) \rightarrow \text{Hidden}(10) \rightarrow \hat{y}. \quad (4.11)$$

После получения прогноза $\hat{y}$ выполнялось обратное преобразование:

$$\hat{\sigma} = 10^{-\hat{y}}. \quad (4.12)$$

«««< HEAD

===== »»»> master

4.4 Реализация вычислительного эксперимента

4.4.1 Процедура обучения

«««< HEAD обучающая часть выборки составляла 90% процентов, а тестовая 10%. Так как для BRANN не нужна валидация результата. ===== обучающая часть выборки составляла 90% процентов, а тестовая 10%. Так как для BRANN не нужна валидация результата. »»»> master

Общая процедура обучения включала следующие этапы:

«««< HEAD формирование входного массива из концентраций легирующих элементов и параметра P_{LM}^* ; ===== формирование входного массива из концентраций легирующих элементов и параметра P_{LM}^* ; »»»> master логарифмическое преобразование целевой переменной σ ; случайное разделение данных на обучающую и валидационную выборки; обучение BRANN-модели; обратное преобразование результата к значениям прочности.

4.4.2 Критерий ошибки

Во время обучения использовалась среднеквадратичная ошибка:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_{predicted,i} - y_{real,i})^2, \quad (4.13)$$

«««< HEAD где $y_{predicted,i}$ — прогноз нейронной сети, $y_{real,i}$ — реальное значение после логарифмического преобразования.

Для оценки точности прогноза прочности использовалась относительная среднеквадратичная ошибка: ===== где $y_{predicted,i}$ — прогноз нейронной сети, $y_{real,i}$ — реальное значение после логарифмического преобразования.

Для оценки точности прогноза прочности использовалась относительная среднеквадратичная ошибка: »»»> master

$$RMSE = \sqrt{\frac{1}{k} \sum_{j=1}^k \left(\frac{\sigma_{predicted,j} - \sigma_{real,j}}{\sigma_{real,j}} \right)^2}. \quad (4.14)$$

«««< HEAD Здесь $\sigma_{predicted,j}$ — предсказанное значение прочности, $\sigma_{real,j}$ — экспериментальное значение прочности, k — количество объектов в выборке.

4.5 Результаты моделирования

Я думаю модель можно было сделать еще лучше, как например в исходной статье, подобрать оптимальные параметры, но ансамбль случайных деревьев без настройки справился гораздо лучше с первой попытки.

Таким образом, модель позволила связать химический состав никелевого суперсплава, температурно-временные условия эксплуатации и изменение прочности.

4.6 Выводы по главе

В данной главе рассмотрена модель прогнозирования жаропрочности никелевых суперсплавов с использованием байесовской регуляризованной искусственной нейронной сети и параметра Ларсона–Миллера. =====
Здесь $\sigma_{predicted,j}$ — предсказанное значение прочности, $\sigma_{real,j}$ — экспериментальное значение прочности, k — количество объектов в выборке.

4.7 Результаты моделирования

Я думаю модель можно было сделать еще лучше, как например в исходной , подобрать оптимальные параметры, но ансамбль случайных деревьев без настройки справился гораздо лучше с первой попытки.

Таким образом, модель позволила связать химический состав никелевого суперсплава, температурно-временные условия эксплуатации и изменение прочности.

4.8 Выводы по главе

В данной главе рассмотрена модель прогнозирования жаропрочности никелевых суперсплавов с использованием байесовской регуляризованной искусственной нейронной сети и параметра Ларсона–Миллера. »»»>
master

Основные особенности подхода заключаются в следующем:

«««< HEAD химический состав и параметр Ларсона–Миллера используются как входные признаки; прочность преобразуется в логарифмическую форму для повышения устойчивости обучения; ===== химический состав и параметр Ларсона–Миллера используются как входные признаки; прочность преобразуется в логарифмическую форму для повышения устойчивости обучения; »»»> master используется BRANN-модель, устойчивая к переобучению;

ЗАКЛЮЧЕНИЕ

Таким образом, в процессе выполнения работы были решены следующие задачи:

а. — — — — — — Была изучена и реализована модель обучения с дифференциальным слоем. В ходе численного эксперимента подтверждено, что данная архитектура позволяет эффективно прогнозировать температуру сольвуса с высокой точностью, что решает первую поставленную задачу.

— Для прогнозирования предела прочности была обучена байесовская регуляризованная нейронная сеть (BRANN). Вторая задача решена в не полном объеме.

— Проведенный сравнительный анализ показал, что воспроизведенные модели демонстрируют результаты, сопоставимые с оригинальными данными из научных статей, что подтверждает их адекватность и применимость в задачах материаловедения.

В пути дальнейшей работы входит донастройка параметров сети и/или проба другой архитектуры нейронно сетию

Таким образом, поставленная цель работы достигнута. Результаты исследования демонстрируют высокий потенциал методов искусственного интеллекта для ускорения разработки и оптимизации состава жаропрочных никелевых суперсплавов.